

5 分钟答辩口播 | 精简版

面向汽车市场洞察与经营决策的 Agent Harness 智能分析工作台

副标题： 一个可被 Agent 驾驶的工程环境 / AI-native Analytics Workspace + Research Runtime

目标时长： 4 分 30 秒-4 分 50 秒

P1 | 封面 | 约 15 秒

我的项目来自汽车市场洞察和经营分析的一线工作。

我想解决的问题是：**企业真正需要沉淀的，不只有数据资产，还有与数据绑定、能够被持续调用的研究能力。**

这就是我要介绍的——**面向汽车市场洞察与经营决策的 Agent Harness 智能分析工作台。**

P2 | 提出一个好问题 | 约 35 秒

过去我们经常强调，一个好的分析师最重要的能力之一，是能够^{***}提出一个好问题^{***}。

这当然来自深度思考、业务理解和经验。

但我越来越意识到，它还有另外一个原因：**研究本身是有成本的，真正稀缺的是研究供给。**

一个问题背后意味着排期、取数、写代码、验证，最后才能形成报告。

所以过去我们必须提前判断什么问题最值得研究，把大量可能有价值的问题挡在研究入口之外。

但如果 AI 能把研究供给扩大很多倍，我们的工作方式是不是也应该发生变化？

P3 | AI 对数据最大的改变 | 约 25 秒

我认为 AI 对企业数据最大的改变，是让数据从^{***}被阅读^{***}走向^{***}被调用^{***}。

过去，数据主要被做成 Dashboard 和 Report，价值受到人的分析带宽限制。

但 AI 出现以后，一次人的提问，可以自动产生很多次查询、比较、计算和验证。

Snowflake 给我的启发是：**AI 的价值不只是分析更快，而是在增加核心数据资产本身的 consumption。**

所以我把数据价值概括为三个乘数：**数据质量、研究能力、调用频率。**

P4 | 三个动作 | 约 35 秒

具体怎么做？我概括成三个动作。

第一，**语义资产化**。把指标、实体和业务定义，从人的经验和临时代码里抽出来。

第二，**方法算子化**。把验证过的分析经验和业务计算方法，变成可测试、可重复调用的 Operator 和 Capability。

第三，**研究 Runtime 化**。统一组织、执行和验证这些能力。

最终形成现在的五层架构，并已经进入三类业务：

MIIT 是产业情报研究，**auto_launch** 是上市与市场动态研究，**NEV APEAL** 是大型用户调研研究。

它们的问题和数据不同，但可以复用同一套底层研究能力。

P5 | Runtime 从工作里长出来 | 约 25 秒

但这套 Runtime 并不是一开始设计出来的，它是从日常工作里长出来的。

最初我做的是 Agent Workspace，让 Agent 进入真实的汽车分析环境完成工作。

后来我发现，更重要的是**工作完成以后留下什么**。

一个方法被反复验证，就应该从临时代码变成 Capability；一个业务口径反复出现，就应该变成 Schema。

所以，**Workspace** 是研究能力的生产现场，**Runtime** 是成熟研究能力的组织和调用方式。

P6 | 增量价值在哪里 | 约 40 秒

那为什么 Agent 和 Runtime 做研究，会产生传统人工研究之外的增量价值？

我的答案并不是 **Agent 比分析师更聪明**。

人擅长理解业务、判断什么重要；机器真正有优势的是**研究的广度、重复次数和边际成本**。

传统研究得到一个 Finding，往往就结束了。

Runtime 却可以继续追问：这个结论在哪些人群成立？边界在哪里？有没有反例？

所以，一次 **Research Run** 不只消费一个问题，也会生产下一批问题。

AI 最大的优势，是把**“继续研究”变得足够便宜**。

当然，研究供给扩大以后，错误也可能同步扩大，所以还必须通过 Evidence、Qualification 和 Validation 约束研究边界。

P7 | NEV APEAL 案例 | 约 50 秒

NEV APEAL 就是一个真实案例。

面对一份 **9,937 × 370** 的问卷数据，我们最初只问：**已有车辆经验，会不会改变用户对新能源车“升级感”的判断？**

发现存在差异以后，我们继续问：**差异来自哪里？**

结果发现主要来自外观、驾驶、动力和座舱，而补能差异很小。

于是又问：**是不是因为配置更多，所以体验更好？**

证据告诉我们，不是。配置数量本身不能解释这种体验差异。

于是问题再次递归：**用户究竟是在评价参数，还是在评价实际体验有没有兑现原来的预期？**

最终产生了新的研究空间——**Expectation Calibration**。

同一份数据最终形成 **25 个 Discovery 视角、16 条 Research Runs 和 70+ Evidence**。

Finding 不再是研究终点，而成为下一轮研究的入口。

P8 | 每一次研究留下什么 | 约 40 秒

但还有一个更重要的问题：

每一次 Research Run 结束以后，除了结论，系统到底留下了什么？

它可以留下新的 Schema，完善业务定义；留下新的 Operator，固定验证过的方法；留下 Evidence，成为以后可以直接引用的证据；留下 Contract 和 Eval，定义结论的边界和验证方式。

所以一次研究实际上同时生产两种东西：

Research Output + Research Capability。

这也是为什么工程上我后来反而减少了 LLM 的作用：

开放问题交给 AI，确定性计算交给代码，结果质量交给 Contract。

当 Schema 越完整、Operator 越丰富、Evidence 越厚，下一次研究的边际成本就越低。

这就是研究复利。

P9 | Value / Vision | 约 25 秒

最后，这套能力首先服务于汽车 OEM、研究机构和企业内部的数据、产品与市场团队。

它的价值不只是提高一次分析效率，而是**提升整个组织的研究供给能力**：让更多问题进入研究，把成熟的方法、口径和研究纪律沉淀成组织资产。

从更大的视角看，这也是 AI 时代释放数据要素价值的一种方式——**让已有数据被更多次、高质量地调用**。

汽车是第一个验证场景，未来希望进一步走向**企业级 Research Runtime**。

让企业数据从静态资产，变成持续产生新决策认知的生产资料。

时间分配

页面	主题	目标时间
P1	项目定义	15 秒

页面	主题	目标时间
P2	研究供给不足	35 秒
P3	从被阅读到被调用	25 秒
P4	三个工程动作	35 秒
P5	Workspace → Runtime	25 秒
P6	Research Compounding	40 秒
P7	NEV APEAL 实证	50 秒
P8	Research Capability / 研究复利	40 秒
P9	Value / Vision	25 秒
合计		约 4 分 30 秒-4 分 50 秒

现场重点停顿

建议在以下三句话后稍作停顿：

- 1. 真正稀缺的是研究供给。
- 2. AI 最大的优势，是把“继续研究”变得足够便宜。
- 3. Research Output + Research Capability。

P7 讲完 “**Finding** 不再是研究终点，而成为下一轮研究的入口” 后，可停顿半秒再翻到 P8，使“每一次研究到底留下什么？”自然承接。