

2026 上海（长三角）中青年工程师创新创业大赛

大数据与智能化赛道初赛 | 8 页 PPT 规划 V2

项目名称：汽车市场洞察智能研究平台

推荐展示名：汽车市场洞察 Research Runtime

副标题：让企业数据从静态资产变成持续产生认知的生产资料

一、V2 的核心变化

V2 不再按“技术能力清单”组织 PPT，而是按一个完整的因果故事推进：

你做了什么？ → 为什么需要？ → 为什么是现在？ → 怎么解决？ → 为什么更有价值？ → 真的跑出来了吗？
→ 为什么可信？ → 最终有什么价值？

整套 PPT 只围绕一个母题：

企业真正需要沉淀的，不只有数据资产，还有与数据绑定、能够持续调用的研究能力。

AI 的作用不是凭空创造研究价值，而是：

把原本依赖个人、低频发生的研究调用，通过工程化放大为机器可以持续执行的研究能力。

二、整套材料的三个核心记忆点

1. 数据本身不是最终资产，研究能力决定数据能被使用多少次

传统企业已经拥有大量数据，但数据价值长期受限于人的分析带宽。

真正决定数据资产价值的，不只是“有多少数据”，还包括：

- 研究能力是否存在；
- 研究方法能否复用；
- 数据能否被持续、高频调用。

2. Research Runtime 的核心，是把研究能力与数据资产绑定

它不是一个通用 Chatbot，也不是一个“更聪明的 Agent”。


它把：

- Semantic Foundation
- Operator / Capability
- Research Workflow
- Contract / Validation


沉淀成长期可调用的工程资产。

3. 一次研究不只产生一个结论，还产生下一次研究的能力

传统研究通常是：



Research Runtime 则形成：



因此：

传统研究产出是一份结论；Research Runtime 的产出，是“结论 + 下一次研究的能力”。

三、8 页 PPT 总结构

页	建议标题	这一页只回答一个问题	核心角色
P1	汽车市场洞察 Research Runtime	我做的到底是什么？	Project Definition
P2	企业拥有大量数据，但研究仍然是一次性的	为什么现在的方法不够？	Problem
P3	AI 让数据从“被阅读”走向“被调用”	为什么现在值得重新做？	Why Now
P4	把一次研究封装成可持续调用的 Research Runtime	mashang-service 到底解决什么？	Solution
P5	Runtime 为什么让同一份数据产生更多价值？	同一份数据为什么会变得更值钱？	Mechanism
P6	同一份新能源调研数据，从一份报告变成研究资产	真的跑出来了吗？	Proof
P7	把“会分析”变成可重复、可验证、可审计的工程能力	为什么不是普通 AI 分析工具？	Engineering Innovation
P8	让企业数据持续产生新的决策认知	最终为什么值得做？	Value / Vision

四、逐页规划

P1 | Project Definition

汽车市场洞察 Research Runtime

副标题

让企业数据从静态资产变成持续产生认知的生产资料

这一页只回答

我做的到底是什么？

核心 Thesis

建议只保留两句话：

企业真正需要沉淀的，不只有数据资产，还有与数据绑定的研究能力。

AI 的价值，是把这种研究能力从人的有限调用，放大为机器可持续执行。

页面内容

- 项目名称
- 项目负责人 / 团队成员
- 一句项目定义
- 一句核心 Thesis

不要放

- 五层架构
- 技术名词堆叠
- MIIT / ELOE / nev_apel 细节
- 代码量、测试量

页面风格

沿用 nev_apel Deck：

- 深海军蓝
- 大标题
- 少量文字
- 汽车 + 数据网络 / 流动光线
- 画面表达“汽车数据被持续调用”

建议时间

15 秒

P2 | Problem

企业拥有大量数据，但研究仍然是一次性的

这一页只回答

为什么现在的方法不够？


核心问题

企业并不缺数据。

真正的问题是：

数据资产与研究能力没有形成长期绑定。

传统研究链路




项目结束以后，往往一起沉没的是

- 临时代码
- 分析方法
- 问题上下文
- 指标口径
- 研究判断经验
- “哪些结论不能讲”的研究纪律

传统研究为什么强调“提出一个好问题”

因为执行一次完整研究的成本太高：



于是组织会主动“节约问题”。

这一页核心句

传统研究真正稀缺的，不只是好问题，而是研究供给能力。

再进一步：

数据很多，但组织没有能力持续研究这些数据。

建议视觉

左侧：传统 Research Project Pipeline

右侧：项目结束后的“资产沉没”示意

建议时间

35 秒


P3 | Why Now

AI 让数据从“被阅读”走向“被调用”

这一页只回答

为什么现在值得重新做这件事？

传统 BI



数据价值受限于人的分析带宽。

AI / Agent 时代



一次业务提问背后，可以自动触发多次数据和计算调用。

三个乘数：AI 改变的不只是效率

维度	传统研究	Runtime 化以后
调用频率	项目制、低频调用	每天 / 每事件 / 持续触发
研究广度	人工挑少数问题	系统可以扫描更多假设
方法复用	方法依附分析师	方法沉淀后跨任务调用

数据资产价值公式

数据资产价值 ≈ 数据质量 × 研究能力 × 调用频率

解释：

- 数据质量：决定能不能用
- 研究能力：决定怎么用
- 调用频率：决定价值被释放多少次

AI / Runtime 重点放大的，是后两个乘数。

Snowflake 的位置

只作为外部启发，不展开公司介绍：

AI 的价值不只是“分析更快”，而是让高质量数据被调用得更多。

这一页最终 Takeaway

AI 不只是让一个问题回答得更快，而是让组织有能力研究原本不会被研究的问题。

建议时间

35 秒


把一次研究封装成可持续调用的 Research Runtime

这一页只回答


mashang-service 到底解决什么？

这一页保持“纯架构”，不承担过多历史演进。

五层架构



纵向逻辑



核心变化

过去：

每一个 Research Project 都重新找数据、写方法、做验证。

现在：

底层语义、分析方法、研究纪律可以被不同 Research Application 持续消费。

Runtime 的职责

```
Context
→ Dispatch
→ Execute
→ Validate
→ Render
```

页面核心句

研究能力沉淀，而不是 Prompt 堆叠。

再进一步：

Research Runtime 的作用，是把研究能力从分析师的临时行为，变成与数据资产长期绑定的工程资产。

三个关键词

- Reusable
- Deterministic
- Verifiable

建议时间

45 秒

P5 | Mechanism

Runtime 为什么让同一份数据产生更多价值？

这一页只回答

同一份数据，为什么经过 Runtime 以后价值会变大？


这一页是整套 PPT 的“机制页”。

核心讲两个机制。


机制 1 | Research Compounding

一次研究会生产下一次研究空间

传统研究：



Runtime 化研究：



核心句

一次 **Research Run** 不只消费一个问题，也会生产下一批问题。

因此同一份数据不会因为“一份报告已经完成”就被研究完。

一次研究还可能产生：

- 新 Hypothesis
- 新 Segment
- 新 Boundary
- 新 Confounder
- 新 Analysis Type
- 新证据需求

机制 2 | Governance

研究空间扩大，但错误不能同步放大

如果 AI 可以研究更多问题，就必须回答：

- 什么能讲？
- 什么不能讲？
- 什么暂时无法回答？

因此 Runtime 同时需要：

Evidence

- Qualification
- Stop-check
- Contract
- Validation

最终形成三种状态：

- **READY**
- **REJECTED**
- **INCONCLUSIVE**

这一页核心结论

Research Runtime 同时扩大研究空间，并约束研究边界。

进一步：

传统研究的产出是一份结论；Research Runtime 的产出，是结论 + 下一次研究的能力。

建议视觉

左右双机制：

左：递归 Research Loop

右：Governance Gate

底部用一条大结论把两边连接。

建议时间

40 秒

P6 | Proof / NEV APEAL

同一份新能源调研数据，从一份报告变成研究资产

这一页只回答

这个机制真的跑出来了吗？

案例：**nev_apéal**

不要展示所有 Topic，只展示一条“Finding → New Question”的真实研究链。

数据基础

- Raw Survey：**9,937 × 370**
- 核心受控分析有效样本：**8,524**

注意：

9,937 是 Raw Survey 总体；8,524 是部分核心受控分析中的有效样本。两者不要混用。

一条真实 Research Chain

Q1

已有车辆经验是否改变用户对“升级感”的判断？

↓

Finding

增购用户的体验评价存在稳定差异。

↓

Q2

这种差异到底来自哪里？

↓

Finding

主要来自：

- 外观
- 驾驶
- 动力
- 座舱

补能差异很小。

↓

Q3

是不是配置更多，所以体验评价更高？

↓

Finding / Counter Evidence

不是。

部分高感知配置与体验有关，但：

配置数量本身不能解释魅力。

↓

Q4

用户真正如何形成评价？

↓

New Research Space

进入：

Expectation Calibration

用户不是简单评价参数，而是在比较：

实际体验是否兑现了原有预期。

用一行数字说明研究规模

可以在页面底部保留：

25 axes Discovery · 16 Research Runs · 70+ Evidence

但它们只能做 supporting evidence，不抢主故事。

页面核心句

同一份数据从“回答一个问题”，变成了“持续生产新问题与新证据的研究资产”。

再补一句：

Finding 不再是研究终点，而是下一轮研究的入口。

建议时间

55 秒

P7 | Engineering Innovation

把“会分析”变成可重复、可验证、可审计的工程能力

这一页只回答

为什么它不是普通的 AI + Excel / RAG / Agent？

研究能力必须工程化

传统 AI 分析工具的核心能力通常是：

能回答问题。

而企业 Research Runtime 要求的是：

同一个问题，下次还能按同样口径重新跑；系统升级以后还能验证结果没有漂移。

七类可信研究工程

1 | Dataset / Schema

统一：

- 指标
- 实体
- 状态
- 业务定义

解决：

到底在分析什么？

2 | Operator

确定性执行关键业务计算。

解决：

关键数字不能由 LLM 临时解释。

3 | Capability

把分析方法封装为可复用研究能力。

解决：

一个方法如何跨问题、跨应用重复使用？

4 | Result Contract

统一：

```
status
scope
result
followup_context
warnings / errors
```

解决：

不同能力的输出如何被机器继续消费？

5 | Evidence / Provenance

记录数字、结论与来源。

解决：

结果从哪里来？

6 | Qualification / Stop-check

明确：

- READY
- REJECTED
- INCONCLUSIVE

解决：

系统什么时候应该停止讲故事？

7 | Eval

Golden Case / Numeric Eval / Render QA。

解决：

系统升级以后，如何确认研究能力没有退化？

工程演进：从 Agentic Loop 到 Research Runtime

这段放在 P7，而不是挤在 P4。

Legacy

LLM Planner
→ Tool Router
→ Agent Loop
→ Dynamic Execution

实际问题：

- 不稳定
- 难测试
- 业务口径易漂移
- Runtime 过重

V2

Context
→ Dispatch
→ Execute
→ Validate
→ Render

工程证据：

- Legacy Agentic Loop：5,562 行
- V2 核心确定性 Pipeline：986 行
- 核心执行代码约 -82%
- Dispatch：config-driven

页面核心句

我们的创新不是让大模型做更多，而是找到哪些事情不应该让大模型做。

职责边界：

开放问题交给 AI，确定性计算交给代码，结果质量交给 Contract。

最后一句

会回答问题 ≠ 可作为企业研究基础设施。

建议时间

50 秒

P8 | Value / Vision

让企业数据持续产生新的决策认知

这一页只回答

最终为什么值得做？

这一页同时回答比赛要求中的：

- 市场价值
- 社会价值
- 数据要素价值
- 产业化潜力

A | 目标用户

- 汽车 OEM
- 咨询 / 用户研究机构
- 企业数据分析团队
- 产品 / 市场 / 销售研究部门

B | 对组织的价值

1. 更强的研究供给

更多问题可以进入研究，而不是只挑最确定的少数问题。

2. 更低的重复研究成本

一次沉淀的方法可以跨任务重复使用。

3. 更短的研究链路

从：

找分析师 → 排期 → 写代码

转向：

Runtime → 调用已有研究能力

4. 更少的个体经验依赖

把：

- 口径
- 方法
- 判断边界
- 研究纪律

从人脑转成组织工程资产。

5. 研究能力形成复利

研究越多：

- Schema 越完整
- Operator 越丰富
- Evidence 越厚
- Contract 越成熟
- 下一次研究边际成本越低

C | 社会价值 / 数据要素价值

传统：

数据 = 被存储的资产

Runtime 化：

数据

×

可调用的研究方法

×

更高调用频率

=

持续产生洞察的研究生产力

数据要素价值释放

让已有数据被更多次高质量调用。

行业赋能

把成熟研究方法沉淀为可以复用的行业基础能力。

组织能力普惠

降低高质量研究对少数资深分析师的依赖。

D | 商业 / 产业愿景

汽车不是终点，而是第一个验证场景。

未来方向：

从汽车市场研究工具 → 企业级 Research Runtime

商业价值不只是“卖一份报告”，而是：

让企业已有的数据和研究能力被更多业务人员、更高频地调用。

页面最终 Takeaway

企业真正需要沉淀的，不只有数据资产，还有与数据绑定、能够持续调用的研究能力。

最后一句：

让企业数据从静态资产，变成持续产生新决策认知的生产资料。

建议时间

25 秒

五、300 秒时间预算

页面	内容	建议时间
P1	Project Definition	15s
P2	Problem	35s

页面	内容	建议时间
P3	Why Now	35s
P4	Solution	45s
P5	Mechanism	40s
P6	NEV APEAL Proof	55s
P7	Engineering Innovation	50s
P8	Value / Vision	25s
总计		300s

正式排练目标

建议不要真的讲满 300 秒。

正式口播控制在：

4 分 35 秒 – 4 分 45 秒

预留：

- 翻页
- 停顿
- 现场节奏变化
- 某页临时多讲 5-10 秒

六、整套 PPT 的故事结构

Act 1 | Problem → Change → Solution

P1

我做的是：

Research Runtime。

P2

因为：

企业数据很多，但研究仍然是一次性的。

P3

现在发生变化：

AI 让数据从“被阅读”走向“被调用”。

P4

所以需要：

把研究能力与数据资产长期绑定。

Act 2 | Mechanism → Proof → Engineering

P5

为什么 Runtime 更有价值：

研究会递归产生新研究空间，同时受到 Governance 约束。

P6

真实证据：

同一份 NEV APEAL 数据真的从一份报告演化成连续研究资产。

P7

为什么可信：

研究能力已经被工程化为可重复、可验证、可审计的系统能力。

Act 3 | So What

P8

最终价值：

让企业已有数据持续产生新的决策认知。

七、V2 的 Hero Pages

最重要的四页：

P3 | Why Now

建立“数据调用经济性发生变化”的时代背景。

P5 | Mechanism

第一次真正解释 Research Runtime 为什么比一次分析更值钱。

P6 | Proof

证明“Research Compounding”不是理论。

P7 | Engineering

证明项目不是一个 Agent Demo，而是工程化 Research Runtime。

八、这版暂时不建议放进主 Deck 的内容

为了 5 分钟叙事集中，继续不展开：

- 8 万+ 行代码
- 377 个 Python 文件
- 920 个测试函数
- Context Parser 92.9%
- 过多 Research Apps
- MIIT 详细抓取流程
- ELOE 完整概率公式
- nev_apcal 全部统计结果
- 商业收费模型细节
- Roadmap
- 内部敏感经营数字

这些内容进入：

Q&A / Backup Slides

九、V2 最终核心定义

项目定义

汽车市场洞察 Research Runtime：把企业数据、研究方法与研究流程封装为可持续调用的研究能力。

商业 / 组织价值定义

数据资产价值 ≈ 数据质量 × 研究能力 × 调用频率

技术定义

开放问题交给 AI，确定性计算交给代码，结果质量交给 Contract。

最终 Thesis

企业真正需要沉淀的，不只有数据资产，还有与数据绑定、能够持续调用的研究能力。

AI 的价值，是把这种研究能力从人的有限调用，放大为机器可持续执行。